



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ»

КАФЕДРА

ИУ7 «ИНФОРМАЦИОННОЕ ОБЕСПЕЧЕНИЕ ЭВМ И ИНФОРМАЦИОННЫЕ ТЕХНОЛОГИИ»

КУРСОВАЯ РАБОТА

НА ТЕМУ:

*Разработка базы данных для хранения наборов
данных (датасетов)*

Студент

ИУ7-62Б

(группа)

(подпись, дата)

(И.О. Фамилия)

Руководитель курсового
проекта

(подпись, дата)

Дроздецкая П.В.

(И.О. Фамилия)

Консультант

(подпись, дата)

(И.О. Фамилия)

2025 г.

РЕФЕРАТ

СОДЕРЖАНИЕ

РЕФЕРАТ	4
СОДЕРЖАНИЕ	5
ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	6
ВВЕДЕНИЕ	7
1 Аналитическая часть	8
1.1 Анализ предметной области	8
1.2 Анализ существующих решений	9
1.3 Формализация задачи	10
1.4 Формализация данных	11
1.5 Формализация ролей	12
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	14

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

ВВЕДЕНИЕ

В последние годы наблюдается стремительный рост количества датасетов, используемых в научных исследованиях, бизнес-аналитике и машинном обучении. Эти наборы данных часто хранятся в разрозненных источниках, без унифицированного подхода к версионированию и поиску. Отсутствие централизованного и структурированного хранилища затрудняет повторное использование и совместную работу. Это порождает необходимость в разработке базы данных, ориентированной на хранение и управление датасетами.

Цель работы — создание программного обеспечения для хранения, версионирования и поиска наборов данных (датасетов).

Для достижения поставленной цели требуется решить следующие задачи:

- провести анализ предметной области и определить ключевые сущности и их взаимосвязи;
- сформулировать функциональные и нефункциональные требования к системе;
- спроектировать структуру базы данных, включая ограничения целостности и ролевую модель;
- реализовать физическую модель базы данных и необходимые механизмы доступа;
- провести исследование влияния различных типов индексов на производительность выполнения запросов.

1 Аналитическая часть

В данной части происходит анализ предметной области, обзор существующих аналогов, формализация хранимой информации, формулировка требований и ограничений, ER-диаграмма сущностей, описание пользователей и диаграмму вариантов использования.

1.1 Анализ предметной области

В современном мире наборы данных (датасеты) стали основой для анализа, машинного обучения, научных исследований и бизнес-аналитики. Под датасетом понимается структурированная коллекция данных, используемая для анализа, обработки или обучения моделей машинного обучения. Датасет состоит из наблюдений (экземпляров) и признаков (характеристик), которые описывают каждое наблюдение. Такие наборы данных используются как входная информация для алгоритмов и моделей, а также для повторного анализа, тестирования и воспроизведения научных результатов [1].

На практике хранение и управление датасетами осуществляется с использованием как специализированных онлайн-платформ (например, Kaggle [2], Hugging Face [3], ClearML [4]), так и в локальных файловых системах. При этом часто возникают проблемы, связанные с отсутствием единых стандартов хранения, невозможностью эффективно отслеживать версии, а также слабо реализованной системой доступа по ролям и поиска по метаданным. Это приводит к потере актуальности данных, дублированию и затруднениям в повторном использовании [5].

Для систем хранения датасетов важно учитывать следующие аспекты:

- версионирование — возможность сохранять историю изменений и откатываться к предыдущим версиям;
- метаданные — структурированная информация о датасете (описание, автор, дата создания, ключевые слова и пр.);
- связь с файлами — каждый датасет может состоять из одного или нескольких файлов разных форматов;
- права доступа — разграничение доступа для разных категорий пользователей (например, гостевой просмотр, авторское редактирование, ад-

министрирование);

— поиск и категоризация — удобная система фильтрации по ключевым словам, тегам, категориям, авторам.

1.2 Анализ существующих решений

Для выявления ключевых требований к системе хранения и управления наборами данных, был проведён анализ четырёх популярных платформ: Kaggle, Hugging Face Datasets, UCI Machine Learning Repository и ClearML. Каждая из этих платформ имеет свою специфику, ориентирована на разные аудитории и задачи, и реализует различные подходы к организации данных.

- 1) Kaggle datasets — платформа для проведения соревнований по анализу данных, а также для обмена датасетами и ноутбуками [2];
- 2) Hugging Face Datasets — открытая платформа для обмена и использования датасетов [3];
- 3) UCI Machine Learning Repository — один из старейших репозиториях, основной упор сделан на академические датасеты [6];
- 4) OpenML — платформа для управления ML-проектами, которая поддерживает загрузку, версионирование и отслеживание датасетов в рамках ML-пайплайнов [7].

Критерии, выделенные для сравнения существующих решений:

- версионирование — поддержка хранения нескольких версий одного и того же датасета с возможностью их отслеживания и восстановления;
- предпросмотр данных — возможность просматривать содержимое датасета (таблицы, примеры, метаданные) без его загрузки;
- отзывы и оценки — наличие системы рейтингов, комментариев и обратной связи от пользователей;
- напоминания об обновлении датасетов — рассылка уведомлений об обновлении датасетов всем скачавшим и зарегистрированным пользователям.

Таблица 1.1 — Сравнение существующих платформ хранения датасетов

Платформа	Версионирование	Предпросмотр данных	Отзывы и оценки	Уведомления об обновлениях
Kaggle	Нет	Да	Да	Нет
Hugging Face	Да	Да	Нет	Нет
UCI	Нет	Нет	Нет	Нет
OpenML	Да	Да	Нет	Да

Все вышеперечисленные существующие решения не предоставляют пользователю полного набора функциональности, необходимой для эффективного хранения и управления датасетами. В частности, лишь единичные платформы одновременно реализуют предпросмотр, уведомления об обновлениях и поддержку версионирования. Таким образом, отличием разрабатываемой системы является обеспечение всех выделенных критериев, что делает её более универсальной и удобной для пользователей.

1.3 Формализация задачи

Необходимо спроектировать базу данных для хранения информации о датасетах, их версиях, связанных файлах, метаданных, тегах, категориях и пользователях. Требуется разработать приложение, предоставляющее интерфейс для просмотра, загрузки, редактирования и удаления информации, хранящейся в базе данных, а также для поиска по ключевым полям и тегам. Необходимо реализовать три вида ролей — гость, авторизованный пользователь и администратор.

В рамках поставленной цели необходимо спроектировать и реализовать базу данных, содержащую информацию о датасетах и их структуре, поддерживающую версионирование, управление доступом и систему уведомлений об обновлениях. Приложение должно обеспечить возможность ведения метаданных, просмотра содержимого и отслеживания изменений, а также предоставлять пользователю удобный интерфейс для взаимодействия с данными в рамках его полномочий.

1.4 Формализация данных

На основании ER-диаграммы были выделены следующие основные категории данных:

- Пользователи
- Роли
- Категории
- Датасеты
- Версии датасетов
- Метаданные
- Отзывы

Таблица 1.2 — Формализация сущностей и их атрибутов

Категория	Сведения о данных (атрибуты)
Пользователь	Идентификатор, Имя пользователя, Пароль, Электронная почта, Страна, Дата регистрации
Роль	Идентификатор, Название
Категория	Идентификатор, Название, Описание
Датасет	Идентификатор, Название, Описание, Уровень доступа, Дата создания, Владелец, Категория
Версия датасета	Идентификатор, Идентификатор датасета, Номер версии, Дата загрузки, Путь к файлу
Метаданные	Идентификатор, Идентификатор датасета, Формат, Размер, Теги
Отзыв	Идентификатор, Пользователь, Датасет, Текст отзыва, Оценка

На рисунке 1.1 приведена ER-диаграмма сущностей в нотации Чена.




Рисунок 1.1 — ER-диаграмма сущностей в нотации Чена

1.5 Формализация ролей

Выделим группы пользователей разрабатываемой системы, исходя из предметной области поставленной задачи.

В системе выделяются 3 типа пользователей:

- гость — неавторизованный пользователь, который имеет возможность просматривать публичные датасеты и их метаданные а также скачивать их;
- авторизованный пользователь — пользователь, прошедший процедуру регистрации и авторизации. Может загружать собственные датасеты, редактировать их метаданные, создавать новые версии;
- администратор — обладает полными правами для управления всеми датасетами, метаданными, а также управляет правами доступа других пользователей, модерирует контент и контролирует работу системы.

На рисунке 1.1 приведена диаграмма вариантов использования.




Рисунок 1.2 — Use-case диаграмма.

Вывод

В данном разделе была проанализирована предметная область, поставленная задача и рассмотрены существующие решения по хранению и управлению датасетами. Проведено сравнение популярных платформ, выявлены их достоинства и недостатки, а также сформулированы ключевые требования к разрабатываемой системе. Поскольку задача предполагает хранение взаимосвязанных структурированных данных, поддержку версионирования, отзывов, тегов и различных ролей пользователей, приоритетными свойствами модели данных являются целостность, расширяемость и независимость от пользовательского интерфейса.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Гульчеев В. А. Секреты датасетов: практическое руководство по анализу и обработке данных. Самиздат, 2023. — С. 42.
2. Kaggle datasets [Электронный ресурс]. Режим доступа: <https://www.kaggle.com/datasets/> (Дата обращения: 16.03.2025).
3. Hugging face datasets [Электронный ресурс]. Режим доступа: <https://huggingface.co/docs/datasets/index> (Дата обращения: 17.03.2025).
4. ClearML datasets [Электронный ресурс]. Режим доступа: <https://clear.ml/docs/latest/docs/hyperdatasets/dataset/> (Дата обращения: 17.03.2025).
5. Чехарин Е. Е. Big data big problems. International Scientific Electronic Journal, 2016. — С. 5.
6. UCI Machine Learning Repository [Электронный ресурс]. Режим доступа: <https://archive.ics.uci.edu/> (Дата обращения: 17.03.2025).
7. Open Machine Learning [Электронный ресурс]. Режим доступа: <https://docs.openml.org//> (Дата обращения: 17.03.2025).